UNIVERSIDADE DE BRASÍLIA
Departamento de Ciência da Computação
Teoria e Aplicação de Grafos (Turma 01, 2026/2)

Análise de uma amostra da rede social do Facebook

Igor Araújo Rodrigues (matrícula 242001517)
Eduardo Marques Pereira (matrícula 211021004)
Terceiro integrante: preencher (matrícula preencher)
Professor: Díbio Brasília, 2026

1 INTRODUÇÃO

Analisamos 404 usuários da rede de amizades do Facebook. Calculamos as centralidades de grau, intermediação, proximidade e autovetor e usamos Louvain para encontrar comunidades. Os dados vêm do conjunto *ego-Facebook* do Stanford Network Analysis Project (2012), formado por dez redes-ego com identificadores anônimos. Comparamos os resultados para entender quais usuários têm mais contatos e quais ocupam posições importantes nos caminhos entre os demais.

2 PREPARAÇÃO DOS DADOS

Construímos um grafo simples, não direcionado e sem pesos com NetworkX (NetworkX Developers, 2026). Lemos as amizades dos arquivos `.edges` e acrescentamos as ligações de cada ego aos amigos da primeira coluna de `.feat`. A união das dez redes resultou em 4.039 nós e 88.234 arestas.

Sorteamos 404 nós sem reposição, com a semente 2026. Depois, selecionamos as arestas com as duas extremidades entre os sorteados, obtendo o subgrafo induzido. Mantivemos os nós que ficaram isolados para analisar todos os 404 usuários. A Tabela 1 reúne as características da amostra.

Tabela 1: Características da amostra

Característica	**Valor**
Nós / arestas	404 / 876
Densidade	0,010761
Grau médio	4,3366
Isolados / componentes conexas	70 / 100
Maior componente	75 nós

Fonte: elaboração própria (2026).

3 CENTRALIDADES E USUÁRIOS DE DESTAQUE

Calculamos as quatro medidas com as funções do NetworkX (NetworkX Developers, 2026). O grau de centralidade corresponde ao número de vizinhos dividido por $N - 1$. A intermediação normalizada mede a participação do usuário nos caminhos mínimos entre pares de outros nós. A proximidade considera a distância média aos nós alcançáveis e usa a correção de Wasserman-Faust para levar em conta essa fração da rede. O autovetor dá mais valor às ligações com usuários também centrais. Ele é obtido de $Ax = \lambda x$, com normalização euclidiana.

Tabela 2: Maior valor de cada centralidade

Centralidade	**Nó**	**Valor**
Grau	1684	0,181141
Intermediação	1684	0,029940
Proximidade	1684	0,181175
Autovetor	2543	0,284588

Fonte: elaboração própria (2026).

O nó 1684 possui 73 vizinhos em uma componente de 75 usuários. Ele está ligado diretamente a quase toda essa componente e lidera grau, intermediação e proximidade. Isso indica um bom alcance inicial para uma informação e uma participação frequente nos caminhos mínimos entre os outros usuários da componente.

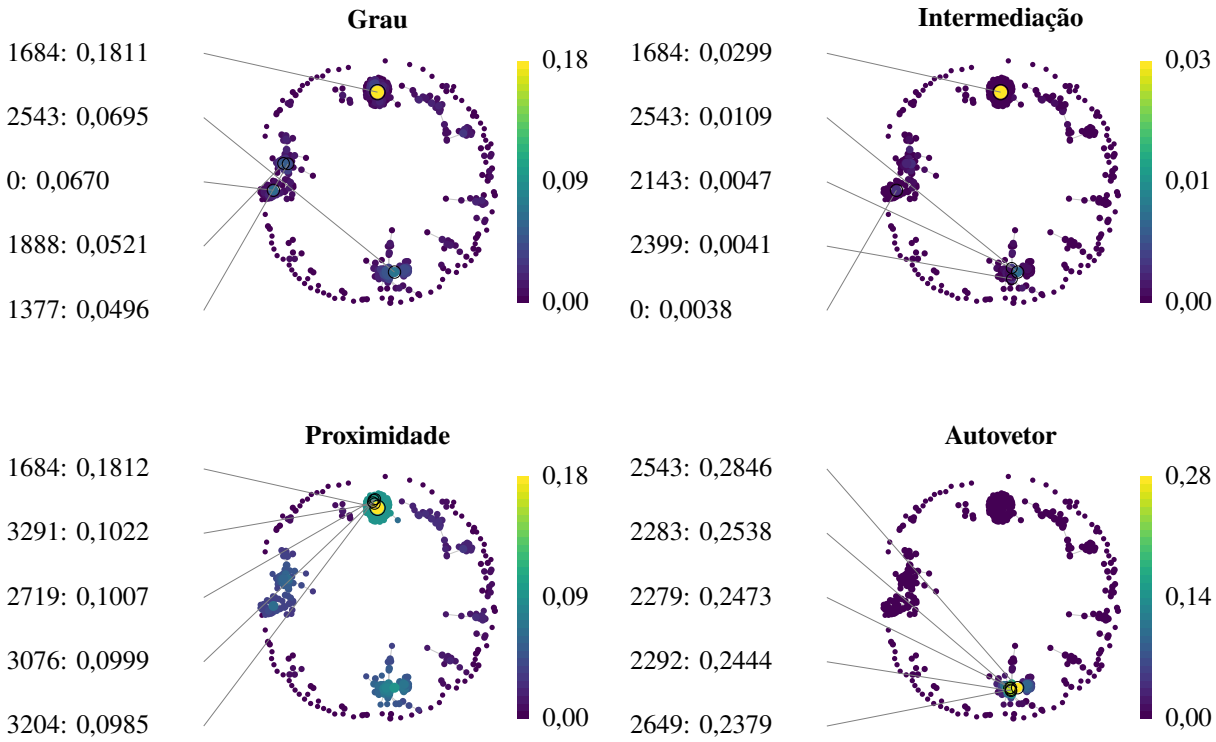
No autovetor, o maior valor é do nó 2543, que pertence a uma componente de 69 nós. Ele tem menos vizinhos que 1684, mas seus vizinhos também têm valores altos de autovetor e contribuem para seu resultado. Por isso, os maiores valores das quatro centralidades nem sempre pertencem ao mesmo usuário.

O grafo tem 100 componentes conexas. Como há usuários sem caminho entre si, a proximidade usa apenas os alcançáveis, com a correção mencionada acima. O autovetor global ficou concentrado na componente de 2543. Ao todo, 335 nós tiveram valor inferior a 10^{-6}, incluindo 1684, apesar de seu alto grau. Usamos iteração de potência com tolerância 10^{-10} e limite de 1.000 iterações. Os isolados receberam zero nas quatro medidas.

4 VISUALIZAÇÃO DAS CENTRALIDADES

Na Figura 1, mantivemos as mesmas posições dos nós nos quatro mapas para facilitar a comparação. Nós maiores têm maior grau. As cores vão do roxo, para os menores valores da medida, ao amarelo, para os maiores. Os cinco usuários com os maiores valores estão identificados ao lado de cada mapa.

Figura 1: Mapas das quatro centralidades e respectivos usuários de destaque



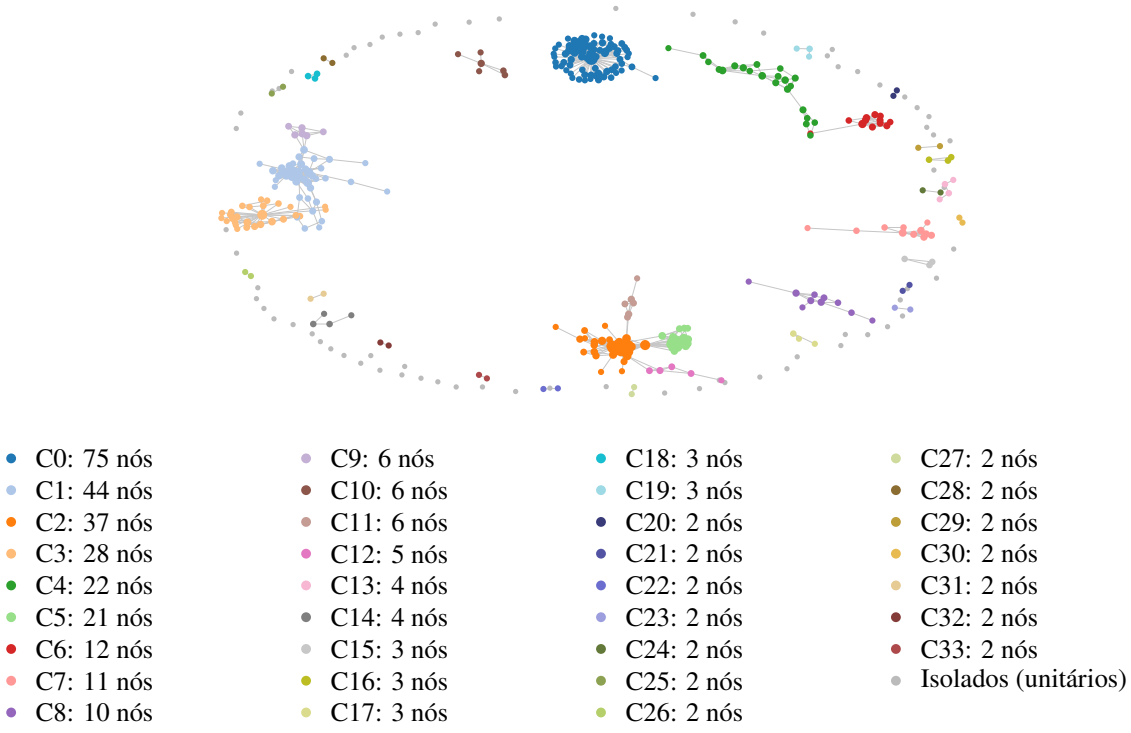
Fonte: elaboração própria (2026).

Nos mapas de grau, intermediação e proximidade, o maior valor é do nó 1684. No autovetor, o maior valor é de 2543, que está em outra componente. O notebook traz os dez maiores valores de cada medida. Os resultados de todos os usuários estão no arquivo `metricas.csv`.

5 COMUNIDADES PELO ALGORITMO DE LOUVAIN

Executamos Louvain com a função do NetworkX, resolução 1 e semente 2026. O algoritmo move nós entre comunidades quando há ganho de modularidade e depois reúne as comunidades em uma rede menor. Essas duas etapas se repetem até que o ganho seja pequeno (Blondel *et al.*, 2008). Encontramos 104 comunidades, com modularidade de 0,821826. O mapa e os tamanhos dos grupos estão na Figura 2.

Figura 2: Comunidades detectadas por Louvain na amostra



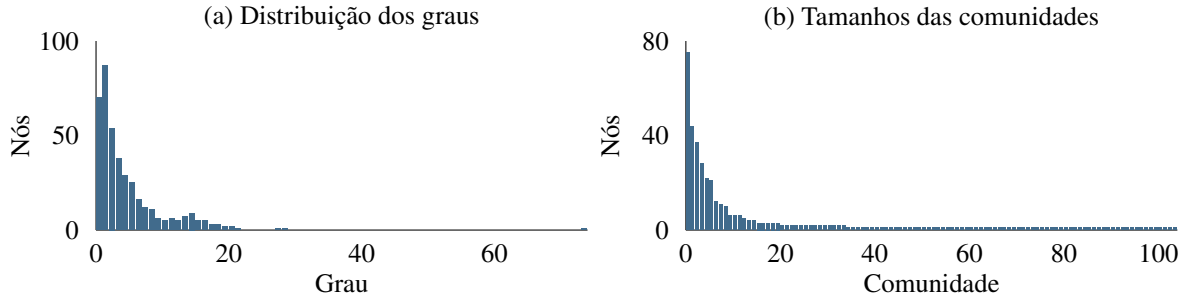
Fonte: elaboração própria (2026).

Dos grupos encontrados, 70 são formados por um único nó isolado. Todos aparecem em cinza, e cada um tem sua própria comunidade. A modularidade alta também está relacionada à separação do grafo em componentes sem ligações entre si. Louvain pode dividir uma componente em mais de uma comunidade. Os grupos foram calculados a partir das arestas; não usamos os círculos de amizade informados nos arquivos `.circles`.

6 CONSIDERAÇÕES FINAIS

O nó 1684 foi o principal usuário nos resultados de grau, intermediação e proximidade. O nó 2543 liderou o autovetor. Para espalhar uma informação pelas amizades da amostra, 1684 teria mais contatos diretos, mas a mensagem ficaria restrita à sua componente. Essa interpretação vem das ligações do grafo, pois não simulamos a propagação de mensagens. A Figura 3 mostra a distribuição dos graus e o tamanho das comunidades encontradas.

Figura 3: Distribuição dos graus e tamanhos das comunidades



Fonte: elaboração própria (2026).

Ao selecionar 404 dos 4.039 usuários, perdemos ligações que existiam na rede completa. Isso ajuda a explicar os nós isolados e as várias componentes conexas. Assim, os resultados se referem aos usuários sorteados e às amizades que permaneceram na amostra. O notebook permite repetir os cálculos, e os arquivos CSV registram a seleção dos nós e os valores das métricas.

REFERÊNCIAS

BLONDEL, Vincent D.; GUILLAUME, Jean-Loup; LAMBIOTTE, Renaud; LEFEBVRE, Etienne. Fast unfolding of communities in large networks. **Journal of Statistical Mechanics: Theory and Experiment**, [S. l.], v. 2008, n. 10, P10008, 2008. DOI: https://doi.org/10.1088/1742-5468/2008/10/P10008.

NETWORKX DEVELOPERS. **NetworkX documentation**. Versão 3.7. [S. l.], 2026. Disponível em: https://networkx.org/documentation/stable/. Acesso em: 12 out. 2026.

STANFORD NETWORK ANALYSIS PROJECT. **Social circles: Facebook**. Stanford, 2012. Disponível em: https://snap.stanford.edu/data/egonets-Facebook.html. Acesso em: 12 out. 2026.